



Universidad Privada del Valle
Facultad de Informática y Electrónica
Carrera de Licenciatura en Ingeniería de Sistemas

**MÓDULO DE INTELIGENCIA PREDICTIVA DEL ERP ISI MUSTANG
BASADO EN EL APROVECHAMIENTO DE DATOS HISTÓRICOS
OPERATIVOS PARA ANTICIPAR DESVIACIONES Y RIESGOS EN
LA GESTIÓN DE PROYECTOS DE INGENIERÍA EPC**

**PROYECTO DE GRADO PARA OPTAR
AL TÍTULO DE
LICENCIATURA EN INGENIERÍA DE SISTEMAS**

POSTULANTE: FRANCO JAVIER TORREZ ALVARADO
TUTOR: ROLANDO LARA SANCHEZ

Santa Cruz – Bolivia

2026

Índice

1 INTRODUCCIÓN	1
2 ANTECEDENTES DEL PROBLEMA	2
2.1 PLANTEAMIENTO DEL PROBLEMA	3
2.1.1 Formulación del Problema	5
2.2 ÁRBOL DEL PROBLEMA	5
2.3 OBJETO DE ESTUDIO	6
3 OBJETIVOS	6
3.1 OBJETIVO GENERAL	6
3.2 OBJETIVOS ESPECÍFICOS	6
4 JUSTIFICACIÓN	7
4.1 JUSTIFICACIÓN TÉCNICA	7
4.2 JUSTIFICACIÓN ECONÓMICA	7
4.3 JUSTIFICACIÓN SOCIAL	7
5 DELIMITACIÓN DE LA INVESTIGACIÓN	8
5.1 TEMÁTICA	8
5.2 ESPACIAL	8
5.3 TEMPORAL	8
6 PROPUESTA DE SOLUCIÓN AL PLANTEAMIENTO DEL PROBLEMA	9
7 DISEÑO METODOLÓGICO	11
7.1 TIPO DE INVESTIGACIÓN	11
7.2 MÉTODO DE INVESTIGACIÓN	12
7.3 TÉCNICAS E INSTRUMENTOS DE INVESTIGACIÓN	13
7.3.1 Técnicas	13
7.3.2 Instrumentos	13
7.4 POBLACIÓN Y MUESTRA	14
8 ÍNDICE TENTATIVO	14
9 MARCO TEÓRICO	16
9.1 SISTEMAS ERP	16
9.2 APRENDIZAJE AUTOMÁTICO	17
9.3 INGENIERÍA DE DATOS	18
9.4 ANALÍTICA PREDICTIVA	19
9.5 GESTIÓN DE PROYECTOS EPC	20
9.6 INGENIERÍA DE SOFTWARE	21
9.7 TECNOLOGÍAS DEL STACK DE DESARROLLO	21

10 CRONOGRAMA	22
REFERENCIAS BIBLIOGRÁFICAS	24
ANEXOS	26
Anexo A. Entrevista a usuario clave del ERP ISI Mustang	27

ÍNDICE DE FIGURAS

2.1	Diagrama de Ishikawa — causas de la gestión reactiva de riesgos en proyectos EPC de ISI Mustang.	4
2.2	Árbol del problema — causas y efectos de la gestión reactiva de desviaciones y riesgos en los proyectos de ISI Mustang.	5
6.1	Arquitectura por capas del módulo predictivo y su integración con el ERP ISI Mustang.	9
6.2	Diagrama de flujo del proceso predictivo — desde los datos históricos del ERP hasta la visualización del resultado por el usuario.	11

ÍNDICE DE CUADROS

2.1	Análisis FODA — ISI Mustang Bolivia respecto a la explotación predictiva de datos del ERP.	4
10.1	Cronograma de actividades del proyecto de grado (2026).	23

ÍNDICE DE ANEXOS

Anexo A. Entrevista semiestructurada aplicada a usuario clave del ERP ISI Mustang	27
---	----

1 INTRODUCCIÓN

Los sistemas ERP constituyen el núcleo operativo de las empresas de ingeniería, registrando de forma continua datos de proyectos, certificaciones, recursos humanos, horas trabajadas, requisiciones y compras. Sin embargo, como señala Hassan et al. (2023), la mayoría de las organizaciones utilizan estos sistemas principalmente para la gestión operativa y la generación de reportes descriptivos, sin explotar el potencial predictivo que ofrecen los datos históricos acumulados. En el ámbito de la gestión de proyectos de ingeniería, el aprendizaje automático ha demostrado superar en precisión a los métodos tradicionales de planificación y control: Akter et al. (2024) demuestra, mediante una revisión sistemática de 39 estudios, que los modelos de inteligencia artificial mejoran significativamente la estimación de costos, mientras que Zhang et al. (2025) propone pipelines automatizados capaces de predecir costos y duración de proyectos con mayor exactitud que las herramientas convencionales basadas en el Earned Value Management.

ISI Mustang Bolivia, empresa con más de 25 años de operación en ingeniería y servicios tecnológicos para los sectores de gas y petróleo, energía y minería, se encuentra precisamente en esta situación. Su ERP acumula más de diez años de datos operativos que incluyen un activo de especial valor para el aprendizaje automático: registros históricos de desviaciones en certificaciones con sus causas documentadas, lo que conforma un conjunto de datos potencialmente etiquetado para aprendizaje supervisado, un activo no siempre disponible en los registros operativos de este tipo de empresas. Kumar et al. (2026) demuestra que modelos como XGBoost alcanzan alta precisión en la predicción de sobrecostos en proyectos de construcción cuando se dispone de datos históricos estructurados, lo que respalda la viabilidad técnica de aprovechar el historial del ERP ISI Mustang para anticipar desviaciones y riesgos operativos.

El presente trabajo propone el desarrollo de un módulo de inteligencia predictiva integrado al ERP ISI Mustang que, mediante técnicas de aprendizaje automático aplicadas sobre datos históricos operativos, permita anticipar desviaciones y riesgos en la gestión de proyectos de ingeniería. El documento se organiza en las siguientes secciones: antecedentes del problema, objetivos, justificación, delimitación de la investigación, propuesta de solución, diseño metodológico, índice tentativo, marco teórico y cronograma.

2 ANTECEDENTES DEL PROBLEMA

La aplicación de técnicas de inteligencia artificial sobre los datos generados por sistemas ERP ha sido objeto de creciente interés en la comunidad académica internacional. Hassan et al. (2023) presenta una revisión comprensiva sobre el uso de aprendizaje automático para la optimización de sistemas ERP, identificando la predicción de desviaciones operativas y la mejora de la toma de decisiones como los casos de uso de mayor impacto. En el ámbito específico de la gestión de proyectos de ingeniería, Akter et al. (2024) sintetiza los resultados de 39 estudios publicados entre 2016 y 2024, concluyendo que los modelos de inteligencia artificial superan consistentemente a los métodos tradicionales en la estimación y predicción de costos.

En cuanto a trabajos específicos que abordan problemas análogos al planteado, Kumar et al. (2026) desarrolló un modelo de XGBoost explicable para predecir sobrecostos en proyectos de construcción a partir de datos históricos estructurados, superando en precisión a modelos tradicionales como la regresión lineal y los árboles de decisión simples; no obstante, su estudio se sustenta en conjuntos de datos del sector construcción y no contempla la integración del modelo en el sistema de información operativo de una empresa. Por su parte, Morales et al. (2025) propuso un marco de XGBoost con restricciones de dominio para la predicción de retrasos en proyectos, alcanzando una precisión del 92 % y reduciendo el error de predicción de tiempo en aproximadamente un 80 % respecto a métodos convencionales como el Earned Value Management; sin embargo, su enfoque exige la definición manual de reglas de dominio y fue validado sobre un conjunto de datos acotado. Finalmente, Zhang et al. (2025) planteó un pipeline automatizado de aprendizaje automático para el pronóstico de costos y duración de proyectos, evidenciando que la integración de múltiples fuentes de datos mejora la precisión predictiva; aun así, dicho pipeline opera sobre datos consolidados de diversas organizaciones y no sobre el historial operativo de una empresa en particular.

Los antecedentes revisados confirman la viabilidad técnica de aplicar aprendizaje automático para anticipar desviaciones y riesgos en proyectos de ingeniería, pero comparten una limitación común: se desarrollan sobre conjuntos de datos públicos o multiorganizacionales y no se integran en el sistema de gestión operativo de la empresa que origina los datos. Adicionalmente, no se

identificaron antecedentes de aplicación de inteligencia predictiva sobre los datos históricos del ERP ISI Mustang ni trabajos similares en el contexto de empresas de ingeniería bolivianas. Esta doble brecha —la ausencia de soluciones integradas al ERP y la falta de precedentes en el contexto local— constituye el punto de partida del presente proyecto de grado.

2.1 PLANTEAMIENTO DEL PROBLEMA

ISI Mustang Bolivia ejecuta proyectos integrales de tipo EPC (Engineering, Procurement and Construction), modalidad en la que la empresa asume de forma completa el diseño de ingeniería, la procura de equipos y materiales, y la construcción de instalaciones para los sectores de gas, petróleo, minería y energía. Para planificar y controlar estos proyectos —avances, certificaciones, recursos, compras y horas trabajadas— la empresa se apoya en un ERP propio, denominado igualmente ISI Mustang, que acumula más de diez años de datos históricos operativos. Sin embargo, dicha información se utiliza únicamente con fines descriptivos y de control inmediato, sin un mecanismo que permita identificar patrones o anticipar comportamientos futuros. Como consecuencia, la detección de desviaciones presupuestarias, retrasos y cuellos de botella ocurre de forma reactiva, limitando la capacidad de gestión proactiva de riesgos en proyectos de alta complejidad técnica y económica.

El diagrama de Ishikawa (Figura 2.1) sintetiza las principales causas que originan esta problemática, mientras que el análisis FODA (Cuadro 2.1) resume la situación de la empresa frente a la explotación predictiva de sus datos.




Figura 2.1. Diagrama de Ishikawa — causas de la gestión reactiva de riesgos en proyectos EPC de ISI Mustang.

Cuadro 2.1. Análisis FODA — ISI Mustang Bolivia respecto a la explotación predictiva de datos del ERP.

Fortalezas • Más de diez años de datos históricos operativos acumulados. • Registros de desviaciones con causas documentadas en el historial de proyectos. • Sistema de información propio con control total sobre los datos operativos.	Oportunidades • Alta demanda de gestión proactiva en proyectos de ingeniería del sector energético. • Creciente disponibilidad de soluciones de análisis predictivo en la industria. • Mejora del posicionamiento competitivo en la estimación y adjudicación de contratos.
Debilidades • Posibles inconsistencias en el registro histórico de información. • Ausencia de una cultura de análisis de datos en la organización. • Dependencia de la disciplina en el registro operativo para la calidad de los resultados.	Amenazas • Resistencia al cambio por parte de los usuarios ante nuevas herramientas de gestión. • Cambios en los procesos operativos pueden reducir la vigencia de los modelos desarrollados. • Baja adopción si los resultados no se comunican de forma clara a los usuarios clave.

2.1.1 Formulación del Problema

¿Cómo aprovechar los datos históricos del ERP ISI Mustang para anticipar desviaciones y riesgos en los proyectos de ingeniería EPC de la empresa?

2.2 ÁRBOL DEL PROBLEMA

El árbol del problema (Figura 2.2) sintetiza las causas que originan la situación descrita y los efectos que de ella se derivan, complementando el análisis de causas presentado en el diagrama de Ishikawa.




Figura 2.2. Árbol del problema — causas y efectos de la gestión reactiva de desviaciones y riesgos en los proyectos de ISI Mustang.

2.3 OBJETO DE ESTUDIO

El proceso de gestión y control de desviaciones y riesgos en los proyectos de ingeniería de ISI Mustang, a partir de los datos históricos registrados en su ERP.

3 OBJETIVOS

3.1 OBJETIVO GENERAL

Desarrollar un módulo de inteligencia predictiva integrado al ERP ISI Mustang, mediante técnicas de aprendizaje automático aplicadas sobre datos históricos operativos, para anticipar desviaciones y riesgos en la gestión de proyectos de ingeniería EPC.

3.2 OBJETIVOS ESPECÍFICOS

- Analizar los datos históricos disponibles en los módulos del ERP ISI Mustang para la identificación de patrones de desviación y la definición de los casos de uso del módulo predictivo.
- Diseñar la arquitectura del módulo predictivo, incluyendo la selección de los modelos de aprendizaje automático adecuados para cada caso de uso.
- Construir el módulo predictivo, comprendiendo el pipeline de datos y el entrenamiento de los modelos para los casos de uso definidos.
- Integrar el módulo predictivo y su dashboard de visualización al ERP ISI Mustang.
- Evaluar la precisión de los modelos y la funcionalidad del módulo mediante métricas de rendimiento y pruebas con usuarios clave de ISI Mustang.

4 JUSTIFICACIÓN

4.1 JUSTIFICACIÓN TÉCNICA

El ERP de ISI Mustang acumula más de diez años de datos operativos distribuidos en múltiples módulos, constituyendo un volumen suficiente para el entrenamiento de modelos de aprendizaje automático. En particular, el módulo de certificaciones contiene registros históricos de desviaciones con sus causas documentadas, que podrían conformar un conjunto de datos etiquetado para aprendizaje supervisado tras una exploración preliminar que confirme su completitud y consistencia. Las técnicas actuales de aprendizaje automático supervisado, en particular los modelos de gradient boosting, son suficientemente maduras para ser aplicadas sobre este tipo de datos tabulares operativos. Además, la integración de un módulo predictivo al ERP existente es técnicamente viable mediante acceso directo a la base de datos del sistema.

4.2 JUSTIFICACIÓN ECONÓMICA

Los proyectos de tipo EPC que ejecuta ISI Mustang en sectores como gas y petróleo, minería y energía involucran presupuestos de alta envergadura, donde la detección temprana de desviaciones puede reducir significativamente los costos de corrección. La anticipación de cuellos de botella en la asignación de recursos permite evitar sobrecostos por sobreasignación o tiempos improductivos. Asimismo, la capacidad predictiva sobre propuestas y proyectos mejora la competitividad de la empresa en la estimación y adjudicación de nuevos contratos.

4.3 JUSTIFICACIÓN SOCIAL

Una gestión de proyectos más proactiva y basada en datos garantiza entregas más confiables en sectores críticos para el desarrollo de Bolivia, como los hidrocarburos, la energía y la minería.

La reducción de la gestión reactiva disminuye la carga operativa de los equipos de proyecto, contribuyendo a mejores condiciones de trabajo. A nivel más amplio, el proyecto demuestra que empresas bolivianas pueden capitalizar sus propios datos históricos mediante inteligencia artificial, aportando al desarrollo tecnológico nacional.

5 DELIMITACIÓN DE LA INVESTIGACIÓN

5.1 TEMÁTICA

El presente trabajo se delimita a las áreas de aprendizaje automático supervisado, ingeniería de datos y analítica predictiva, aplicadas sobre los datos operativos del ERP ISI Mustang. En cuanto a la gestión de proyectos, el estudio se circunscribe a proyectos de tipo EPC ejecutados por ISI Mustang. Quedan fuera del alcance las fuentes de datos externas al ERP, como sensores IoT, datos de mercado o información climática, así como los módulos del sistema que no se encuentren activos o poblados con datos históricos suficientes.

5.2 ESPACIAL

El estudio se desarrolla en las instalaciones de ISI Mustang Bolivia, con sede en Santa Cruz de la Sierra, Bolivia. Los datos históricos utilizados corresponden a proyectos ejecutados por la empresa principalmente en territorio boliviano. El módulo de inteligencia predictiva desarrollado será integrado y validado en el ERP operativo de ISI Mustang en su sede central.

5.3 TEMPORAL

Los datos históricos utilizados para el entrenamiento de los modelos de aprendizaje automático

abarcan un período de más de diez años de operación del ERP ISI Mustang. El desarrollo del proyecto de grado se estima entre abril y agosto de 2026, período que comprende las etapas de análisis, diseño, construcción y evaluación del módulo predictivo.

En cuanto a la validez temporal de la investigación, dado que los modelos predictivos se entrenan sobre patrones históricos, se estima que la solución mantiene su vigencia mientras las condiciones operativas de la empresa permanezcan estables. Se recomienda un reentrenamiento periódico de los modelos —de forma anual o ante cambios sustanciales en los procesos de la empresa— con el fin de mitigar la pérdida de precisión por deriva de datos (*model drift*).

6 PROPUESTA DE SOLUCIÓN AL PLANTEAMIENTO DEL PROBLEMA

Se propone el desarrollo de un módulo de inteligencia predictiva organizado como una arquitectura por capas, que abarca desde las fuentes de datos del ERP hasta la presentación de las predicciones al usuario. La solución se integra al ERP existente de ISI Mustang sin modificar su arquitectura central: el módulo predictivo opera como un componente independiente que consume los datos históricos del sistema y expone sus resultados a través de un microservicio. La Figura 6.1 presenta esta arquitectura, diferenciando los componentes nuevos del módulo predictivo de los componentes ya existentes del ERP.




Figura 6.1. Arquitectura por capas del módulo predictivo y su integración con el ERP ISI Mustang.

Siguiendo la arquitectura Medallion, la capa de fuentes (Bronze) reúne los datos operativos crudos del ERP (PostgreSQL) junto con datos complementarios en archivos (CSV/Parquet); la capa de unificación (Silver) los consolida y depura mediante DuckDB; la capa de transformación (Gold) realiza la ingeniería de variables con Polars; y la capa de modelos entrena los modelos predictivos para los casos de uso definidos. Posteriormente, la capa de servicio expone los modelos como una API REST con FastAPI, que el backend NestJS del ERP consume para presentar las predicciones en un dashboard de Angular.

El siguiente diagrama de flujo (Figura 6.2) describe el proceso predictivo de extremo a extremo, desde los datos históricos hasta la visualización del resultado por el usuario.




Figura 6.2. Diagrama de flujo del proceso predictivo — desde los datos históricos del ERP hasta la visualización del resultado por el usuario.

7 DISEÑO METODOLÓGICO

7.1 TIPO DE INVESTIGACIÓN

El presente trabajo corresponde a una investigación aplicada, dado que utiliza conocimiento

científico existente en el área del aprendizaje automático para dar solución a un problema concreto en el contexto operativo de ISI Mustang Bolivia. De acuerdo con sus fases, combina tres niveles de alcance: exploratorio, en la etapa inicial de comprensión y caracterización de los datos históricos del ERP; descriptivo, para identificar y caracterizar las variables operativas relevantes y los patrones de desviación; y correlacional, al modelar las relaciones entre dichas variables —como horas trabajadas, líneas de presupuesto y certificaciones— con el fin de anticipar desviaciones y riesgos en proyectos de ingeniería.

7.2 MÉTODO DE INVESTIGACIÓN

El presente trabajo adopta un enfoque mixto, dado que combina la recolección y el análisis de datos cuantitativos —los registros históricos almacenados en el ERP— con datos cualitativos provenientes de las entrevistas a usuarios clave. Para operacionalizar este enfoque se emplean los siguientes métodos:

Análisis documental: se utilizará para la revisión de literatura científica sobre aprendizaje automático, analítica predictiva y sistemas ERP, con el fin de establecer los fundamentos teóricos del trabajo.

Histórico-lógico: se aplicará sobre los datos históricos acumulados en el ERP durante más de diez años de operación, permitiendo identificar patrones y tendencias en el comportamiento de los proyectos a lo largo del tiempo.

Modelación: se empleará para la construcción de modelos matemáticos de aprendizaje automático que representen el comportamiento de las variables operativas y permitan generar predicciones.

Enfoque de sistemas: se utilizará para analizar el ERP ISI Mustang como un sistema con entradas, procesos y salidas, identificando las interrelaciones entre sus módulos y los flujos de datos relevantes para el módulo predictivo.

7.3 TÉCNICAS E INSTRUMENTOS DE INVESTIGACIÓN

7.3.1 Técnicas

Análisis de datos: se aplicará sobre los registros históricos almacenados en el ERP ISI Mustang, con el propósito de identificar variables predictoras, detectar patrones de comportamiento y construir los conjuntos de datos necesarios para el entrenamiento de los modelos de aprendizaje automático.

Entrevista: se aplicará a usuarios clave del ERP en ISI Mustang Bolivia, con el fin de relevar requisitos funcionales del módulo predictivo, validar las predicciones generadas y recoger criterios de utilidad desde la perspectiva operativa.

Pruebas de los modelos predictivos: se aplicarán sobre un conjunto de datos de prueba independiente para evaluar el desempeño de los modelos entrenados. Para los casos de clasificación se emplearán indicadores como la exactitud, la precisión, la sensibilidad, el F1-score y la matriz de confusión; para los casos de regresión se utilizarán el error cuadrático medio (RMSE), el error absoluto medio (MAE) y el coeficiente de determinación (R^2). Adicionalmente, se aplicará validación cruzada para verificar la estabilidad de los resultados.

7.3.2 Instrumentos

Para el análisis de datos: scripts de extracción y transformación de datos, y cuadernos de análisis exploratorio (notebooks).

Para la entrevista: guía de entrevista semiestructurada dirigida a usuarios clave del sistema.

Para las pruebas de los modelos: cuadro de métricas de evaluación y rutinas de validación cruzada.

7.4 POBLACIÓN Y MUESTRA

Análisis de datos: la población corresponde a la totalidad de registros históricos generados en el ERP ISI Mustang durante su período operativo. Se trabajará con el conjunto completo de datos disponibles en los módulos relevantes para los casos de predicción definidos.

Entrevista: la población está conformada por aproximadamente 20 usuarios del ERP en ISI Mustang Bolivia. La muestra será de 5 a 8 usuarios clave seleccionados mediante muestreo no probabilístico intencional, priorizando perfiles con roles de jefe de proyecto, certificador y administrador del sistema.

8 ÍNDICE TENTATIVO

INTRODUCCIÓN

CAPÍTULO I. MARCO GENERAL

- 1.1 Antecedentes
- 1.2 Planteamiento del Problema
 - 1.2.1 Formulación del Problema
- 1.3 Objetivos
 - 1.3.1 Objetivo General
 - 1.3.2 Objetivos Específicos
- 1.4 Justificación
 - 1.4.1 Justificación Técnica
 - 1.4.2 Justificación Económica
 - 1.4.3 Justificación Social
- 1.5 Metodología
 - 1.5.1 Tipo de Investigación
 - 1.5.2 Método de Investigación
 - 1.5.3 Técnicas e Instrumentos de Investigación
 - 1.5.4 Población y Muestra

CAPÍTULO II. MARCO TEÓRICO Y TECNOLÓGICO

- 2.1 Sistemas ERP
 - 2.1.1 Definición y Características
 - 2.1.2 ERP en Empresas de Ingeniería
 - 2.1.3 ERP en el Sector de Petróleo, Gas y Minería
- 2.2 Aprendizaje Automático
 - 2.2.1 Tipos de Aprendizaje
 - 2.2.2 Aprendizaje Supervisado
 - 2.2.3 Algoritmos de Aprendizaje Supervisado: Gradient Boosting y XGBoost

- 2.2.4 Feature Engineering
- 2.3 Ingeniería de Datos
 - 2.3.1 Procesos ETL y ELT
 - 2.3.2 Arquitectura Medallion (Bronze, Silver, Gold)
 - 2.3.3 Calidad de Datos
- 2.4 Analítica Predictiva
 - 2.4.1 Definición y Aplicaciones
 - 2.4.2 Analítica Predictiva en Gestión de Proyectos
 - 2.4.3 Predicción de Desviaciones y Costos
- 2.5 Gestión de Proyectos EPC
 - 2.5.1 Definición y Características
 - 2.5.2 Certificaciones y Control de Avance
 - 2.5.3 Desviaciones Presupuestarias y de Cronograma
- 2.6 Ingeniería de Software
 - 2.6.1 Proceso de Desarrollo de Software
 - 2.6.2 Metodología de Desarrollo Iterativa e Incremental
 - 2.6.3 Arquitectura de Software por Capas
- 2.7 Tecnologías del Stack de Desarrollo
 - 2.7.1 Python y su Ecosistema ML
 - 2.7.2 DuckDB y Polars
 - 2.7.3 FastAPI como Microservicio
 - 2.7.4 NestJS y Angular

CAPÍTULO III. ANÁLISIS Y DISEÑO DEL SISTEMA PROPUESTO

- 3.1 Análisis de Datos Históricos del ERP
 - 3.1.1 Exploración y Caracterización de Datos
 - 3.1.2 Identificación de Variables Predictoras
 - 3.1.3 Definición de Casos de Uso Predictivos
- 3.2 Requerimientos del Sistema
 - 3.2.1 Requerimientos Funcionales
 - 3.2.2 Requerimientos No Funcionales
- 3.3 Diseño de la Arquitectura del Módulo Predictivo
 - 3.3.1 Arquitectura por Capas
 - 3.3.2 Diseño del Pipeline de Datos
 - 3.3.3 Diseño de Modelos ML
 - 3.3.4 Diseño de la API Predictiva
 - 3.3.5 Diseño del Dashboard

CAPÍTULO IV. CONSTRUCCIÓN E IMPLEMENTACIÓN DEL SISTEMA

- 4.1 Pipeline de Extracción y Transformación de Datos
 - 4.1.1 Integración DuckDB con PostgreSQL
 - 4.1.2 Transformación de Datos con Polars
 - 4.1.3 Feature Engineering
- 4.2 Entrenamiento de Modelos Predictivos
 - 4.2.1 Modelo de Desviación en Certificaciones
 - 4.2.2 Modelo de Sobre costo de Proyectos
 - 4.2.3 Modelo de Retraso en Cronograma
- 4.3 Desarrollo del Microservicio FastAPI
- 4.4 Integración con el ERP

- 4.4.1 Endpoints de Predicción en NestJS
- 4.4.2 Dashboard de Inteligencia Predictiva en Angular
- 4.5 Evaluación y Validación
 - 4.5.1 Métricas de Rendimiento de Modelos
 - 4.5.2 Pruebas con Usuarios Clave
- CONCLUSIONES
- RECOMENDACIONES
- REFERENCIAS BIBLIOGRÁFICAS
- ANEXOS

9 MARCO TEÓRICO

Los fundamentos teóricos del presente trabajo se organizan en siete áreas del conocimiento: sistemas ERP, aprendizaje automático, ingeniería de datos, analítica predictiva, gestión de proyectos EPC, ingeniería de software y tecnologías del stack de desarrollo. Cada área aporta los conceptos necesarios para comprender el problema, justificar el enfoque metodológico y sustentar las decisiones técnicas del módulo propuesto.

9.1 SISTEMAS ERP

Los sistemas de planificación de recursos empresariales (ERP, por sus siglas en inglés Enterprise Resource Planning) son plataformas de software integradas que centralizan y gestionan los procesos operativos de una organización en un único sistema de información. Un ERP reúne datos de múltiples áreas funcionales —como finanzas, recursos humanos, compras, producción y gestión de proyectos— en una base de datos compartida, eliminando la fragmentación de la información y proporcionando una visión unificada de las operaciones (Hassan et al., 2023).

En el contexto de empresas de ingeniería, los sistemas ERP adquieren una dimensión especial dado que deben gestionar proyectos de alta complejidad técnica y económica, con múltiples etapas, equipos multidisciplinarios y presupuestos considerables. Rashid y Al-Azri (2019) destaca que la implementación de ERP en el sector de petróleo y gas presenta desafíos específicos relacionados con la trazabilidad de costos por proyecto, la gestión de recursos en campo y el

control de certificaciones periódicas.

A pesar de que los sistemas ERP generan volúmenes significativos de datos operativos a lo largo de su ciclo de vida, la explotación analítica de dichos datos ha sido históricamente limitada. Hassan et al. (2023) señala que la mayoría de las organizaciones utilizan sus ERP principalmente para la gestión operativa y la generación de reportes descriptivos, sin aprovechar el potencial predictivo que ofrecen los datos históricos acumulados. Este escenario representa una oportunidad para la aplicación de técnicas de aprendizaje automático sobre los datos del ERP, con el fin de transformar la información histórica en capacidad predictiva.

9.2 APRENDIZAJE AUTOMÁTICO

El aprendizaje automático (machine learning) es una rama de la inteligencia artificial que desarrolla algoritmos capaces de aprender patrones a partir de datos y realizar predicciones sin ser explícitamente programados para cada tarea. A diferencia de los sistemas basados en reglas, los modelos de aprendizaje automático mejoran su rendimiento a medida que disponen de mayor cantidad de datos de entrenamiento.

El aprendizaje supervisado es el paradigma más relevante para el presente trabajo. En este enfoque, el modelo se entrena con un conjunto de datos etiquetados, es decir, datos para los cuales se conoce el resultado esperado. A partir de estos ejemplos, el modelo aprende la relación entre las variables de entrada (features) y la variable objetivo, con el fin de generalizar dicha relación a nuevos datos. Dentro del aprendizaje supervisado se distinguen dos tipos de tareas: la clasificación, cuyo objetivo es predecir una categoría discreta, y la regresión, cuyo objetivo es predecir un valor continuo. Para el módulo predictivo propuesto, ambos tipos son aplicables: clasificación para determinar si un proyecto presentará desviación, y regresión para estimar la magnitud de dicha desviación.

Entre los algoritmos de aprendizaje supervisado más utilizados en la predicción de resultados en proyectos de ingeniería destaca el gradient boosting, y en particular XGBoost (Extreme Gradient

Boosting). Kumar et al. (2026) demuestra que los modelos XGBoost ofrecen alta precisión en la predicción de sobrecostos en proyectos de construcción, superando a modelos tradicionales como la regresión lineal y los árboles de decisión simples. De forma complementaria, y a título referencial dado que se trata de un manuscrito aún no publicado, Morales et al. (2025) reporta una precisión del 92 % en la predicción de retrasos en proyectos utilizando un marco XGBoost con restricciones de dominio, reduciendo el error de predicción de tiempo en aproximadamente un 80 % respecto a métodos convencionales como el Earned Value Management.

El proceso de feature engineering —preparación y transformación de variables para el entrenamiento de modelos— es fundamental para el rendimiento de los modelos sobre datos tabulares. Consiste en seleccionar, transformar y crear variables relevantes a partir de los datos brutos, con el objetivo de maximizar la capacidad predictiva del modelo. En el contexto de datos operativos de un ERP, el feature engineering implica la creación de variables derivadas como ratios de consumo presupuestario, tendencias de horas cargadas por período o indicadores de velocidad de certificación.

9.3 INGENIERÍA DE DATOS

La ingeniería de datos proporciona los procesos que transforman los datos operativos crudos en conjuntos de datos confiables y listos para el entrenamiento de modelos. Reis y Housley (2022) distinguen dos enfoques para el movimiento y la preparación de datos: el ETL (Extract, Transform, Load), en el cual la información se transforma antes de cargarse en el destino, y el ELT (Extract, Load, Transform), en el cual los datos crudos se cargan primero y la transformación se realiza dentro del propio motor analítico. Para el presente trabajo se adopta el enfoque ELT, dado que permite consolidar los datos del ERP sin transformaciones previas y aprovechar la capacidad de DuckDB como motor analítico embebido para ejecutar las transformaciones sobre los datos ya integrados, simplificando el pipeline y preservando los datos originales para su reprocesamiento.

Para organizar este pipeline se adopta la arquitectura Medallion, un patrón que estructura los datos en tres capas de calidad progresiva —Bronze, Silver y Gold— donde cada capa refina

e incrementa el valor de los datos respecto a la anterior (Databricks, 2025). La capa Bronze conserva los datos crudos tal como se extraen de las fuentes; la capa Silver realiza la limpieza, deduplicación y conformado; y la capa Gold entrega conjuntos de datos enriquecidos y agregados, optimizados para el consumo de los modelos de aprendizaje automático. Si bien este patrón se popularizó en entornos de tipo lakehouse, constituye un patrón lógico de organización agnóstico de la herramienta, plenamente aplicable sobre DuckDB y archivos Parquet sin requerir infraestructura especializada. En el módulo propuesto, las capas de fuentes, unificación y transformación de la arquitectura se corresponden, respectivamente, con los niveles Bronze, Silver y Gold de este patrón.

La adopción de un esquema de refinamiento progresivo aporta, además, un mecanismo de control de calidad de los datos: cada capa aplica validaciones y depuraciones que mejoran la confiabilidad de la información antes de alimentar los modelos. Este aspecto resulta especialmente relevante dado que, como se identificó en el análisis FODA, el registro histórico del ERP puede contener inconsistencias; el tratamiento por capas permite detectarlas y corregirlas de forma sistemática antes del entrenamiento.

9.4 ANALÍTICA PREDICTIVA

La analítica predictiva es un conjunto de técnicas estadísticas y de aprendizaje automático que permite anticipar comportamientos futuros a partir del análisis de datos históricos. A diferencia de la analítica descriptiva, que responde a la pregunta de qué ocurrió, la analítica predictiva responde a qué ocurrirá, proporcionando a las organizaciones una capacidad proactiva de gestión frente a los riesgos.

En el ámbito de la gestión de proyectos de ingeniería, la analítica predictiva ha demostrado ser una herramienta de alto valor para la anticipación de desviaciones presupuestarias y retrasos en el cronograma. La evidencia empírica respalda este enfoque: Akter et al. (2024) concluye, a partir de una amplia revisión sistemática, que los modelos basados en inteligencia artificial —particularmente los de gradient boosting— mejoran significativamente la precisión de

la estimación de costos en comparación con los métodos convencionales. Zhang et al. (2025) propone un pipeline automatizado de aprendizaje automático para la predicción de costos y duración de proyectos, demostrando que la integración de múltiples fuentes de datos operativos mejora la precisión predictiva respecto a modelos entrenados con una sola fuente.

Investigaciones recientes indican que los modelos predictivos aplicados a proyectos de ingeniería pueden identificar señales de riesgo con semanas de anticipación. Pereira et al. (2022) reporta que los modelos de aprendizaje automático basados en datos históricos de proyectos producen estimaciones de costo más precisas que los índices tradicionales del Earned Value Management, con una reducción significativa en el error de predicción. Estos hallazgos sustentan la viabilidad de aplicar analítica predictiva sobre los datos históricos del ERP ISI Mustang para anticipar desviaciones operativas.

9.5 GESTIÓN DE PROYECTOS EPC

Los proyectos de tipo EPC (Engineering, Procurement and Construction) son una modalidad de contratación integral en la industria de ingeniería, en la cual una empresa asume la responsabilidad completa del diseño de ingeniería, la adquisición de equipos y materiales, y la construcción de una instalación. Esta modalidad es prevalente en sectores como petróleo y gas, minería y energía, donde los proyectos involucran alta complejidad técnica, presupuestos considerables y plazos estrictos.

Las desviaciones de costo y cronograma en proyectos EPC son un problema recurrente y de alto impacto económico. Zainol et al. (2022) identifica como causas principales de sobre costo en proyectos EPC de petróleo y gas la gestión inadecuada de materiales, estimaciones de costo imprecisas y deficiencias en la planificación de recursos. Herrera et al. (2018) señala que los cambios de diseño constituyen la causa más común de retraso y sobre costo tanto en las fases de ingeniería como de construcción.

El control del avance en proyectos EPC se realiza mediante certificaciones periódicas, que

registran el monto estimado, el monto de seguimiento y el monto efectivamente ejecutado en cada período. La diferencia entre lo estimado y lo certificado constituye la desviación, la cual es acompañada en muchos sistemas de gestión por una causa documentada y un plan de mitigación. Esta estructura de datos —desviación con causa etiquetada— representa una fuente de aprendizaje supervisado de alto valor para el entrenamiento de modelos predictivos.

9.6 INGENIERÍA DE SOFTWARE

La ingeniería de software proporciona los principios y modelos que ordenan la construcción del módulo predictivo como un producto de software mantenible e integrable. Dado que el módulo no se desarrolla de forma aislada sino que debe acoplarse al ERP existente de ISI Mustang, su construcción se rige por un modelo de desarrollo iterativo e incremental, en el cual el sistema se elabora en ciclos sucesivos que agregan funcionalidad de manera progresiva (Sommerville, 2011). Este enfoque permite validar tempranamente cada caso de uso predictivo con los usuarios de la empresa, incorporar ajustes a partir de la retroalimentación y reducir el riesgo asociado a entregas de gran alcance, frente a los modelos secuenciales tradicionales.

La organización interna del módulo sigue una arquitectura de software por capas, patrón que separa las responsabilidades del sistema en niveles independientes —fuentes de datos, unificación, transformación, modelos, servicio e integración— de modo que cada capa solo se comunica con las adyacentes (Bass et al., 2012). Esta separación favorece la mantenibilidad, facilita la sustitución o evolución de componentes individuales sin afectar al resto del sistema y permite que el módulo se integre con el ERP a través de una interfaz de servicio bien definida, sin acoplarse a la implementación interna del sistema existente.

9.7 TECNOLOGÍAS DEL STACK DE DESARROLLO

El ecosistema de Python se ha consolidado como el estándar para el desarrollo de soluciones de aprendizaje automático, gracias a la disponibilidad de librerías especializadas de

alto rendimiento. Para el presente trabajo se seleccionaron herramientas modernas orientadas al procesamiento eficiente de datos y al despliegue de modelos predictivos como servicios integrados.

DuckDB es un motor de base de datos analítico embebido, diseñado para ejecutar consultas SQL complejas sobre múltiples fuentes de datos —incluyendo bases de datos relacionales y archivos en formatos como CSV y Parquet— con alto rendimiento y sin requerir infraestructura adicional. Su capacidad para integrar datos de PostgreSQL con fuentes externas lo convierte en una herramienta adecuada para el pipeline de preparación de datos del módulo predictivo.

Polars es una librería de procesamiento de datos tabulares escrita en Rust, que ofrece un rendimiento superior a librerías tradicionales como Pandas para operaciones de transformación y agregación sobre grandes volúmenes de datos. FastAPI es un framework para el desarrollo de APIs REST en Python, caracterizado por su alto rendimiento y arquitectura asíncrona, que permite exponer los modelos entrenados como un microservicio consumible por el backend del ERP. La integración de estos componentes con el stack existente de NestJS y Angular permite incorporar las capacidades predictivas directamente en la interfaz del ERP sin modificar su arquitectura central.

10 CRONOGRAMA

El desarrollo del proyecto de grado se planifica en un período de cinco meses, entre abril y agosto de 2026. El Cuadro 10.1 detalla las actividades distribuidas por mes, abarcando desde la elaboración del perfil hasta la presentación y defensa final, en correspondencia con los objetivos específicos planteados.

Cuadro 10.1. Cronograma de actividades del proyecto de grado (2026).

Actividad	Abril	Mayo	Junio	Julio	Agosto
Elaboración y presentación del perfil	X				
Revisión y aprobación por el tribunal	X				
Elaboración del marco teórico	X	X			
Análisis de datos históricos del ERP	X	X			
Diseño de la arquitectura y selección de modelos		X			
Construcción del pipeline y entrenamiento de modelos			X		
Integración del módulo y dashboard al ERP				X	
Evaluación y validación con usuarios clave					X
Redacción del documento final				X	X
Presentación y defensa					X

Leyenda: la celda sombreada con **X** indica el mes en que se ejecuta la actividad.

REFERENCIAS BIBLIOGRÁFICAS

- Akter, S., et al. (2024). Advancement of Artificial Intelligence in Cost Estimation for Project Management Success: A Systematic Review of Machine Learning, Deep Learning, Regression, and Hybrid Models. *Machine Learning and Knowledge Extraction*, 6(2), 35. <https://doi.org/10.3390/make6020035>
- Bass, L., Clements, P., & Kazman, R. (2012). *Software Architecture in Practice* (3.^a ed.). Addison-Wesley Professional.
- Databricks. (2025). *What is the medallion lakehouse architecture?* Databricks Documentation. Consultado el 19 de junio de 2026, desde <https://docs.databricks.com/aws/en/lakehouse/medallion>
- Hassan, A., et al. (2023). Machine learning-driven optimization of enterprise resource planning (ERP) systems: a comprehensive review. *Beni-Suef University Journal of Basic and Applied Sciences*. <https://doi.org/10.1186/s43088-023-00460-y>
- Herrera, R., et al. (2018). Engineering, Procurement, and Construction Cost and Schedule Performance Leading Indicators: State-of-the-Art Review. *Construction Research Congress 2018*. <https://doi.org/10.1061/9780784481271.037>
- Kumar, R., et al. (2026). An explainable XGBoost model for predicting cost overruns in construction projects. *Asian Journal of Civil Engineering*. <https://doi.org/10.1007/s42107-026-01686-8>
- Morales, D., et al. (2025). *Domain-Aware Machine Learning for Project Delay Prediction: A Rule-Constrained XGBoost Framework* [Manuscrito no publicado. ResearchGate].
- Pereira, E., et al. (2022). A Machine Learning Study to Enhance Project Cost Forecasting. *IFAC-PapersOnLine*. <https://doi.org/10.1016/j.ifacol.2022.09.537>
- Rashid, M., & Al-Azri, N. (2019). ERP Implementation in the Oil and Gas Sector: A Case Study in Sultanate of Oman. *2019 International Conference on Computer and Information Sciences (ICCIS)*. <https://doi.org/10.1109/ICCISci.2019.8748779>
- Reis, J., & Housley, M. (2022). *Fundamentals of Data Engineering: Plan and Build Robust Data Systems*. O'Reilly Media.
- Sommerville, I. (2011). *Software Engineering* (9.^a ed.). Addison-Wesley.
- Zainol, N., et al. (2022). Cost Overruns in Engineering Procurement Construction (EPC) Fabrication Oil and Gas Megaprojects in Malaysia: The Importance of Resource Allocation (5M). *International Journal of Academic Research in Business and Social Sciences*.
- Zhang, W., et al. (2025). Automated machine learning pipeline for robust project cost and duration forecasting. *Automation in Construction*. <https://doi.org/10.1016/j.autcon.2025.004662>

ANEXOS

Anexo A. Entrevista semiestructurada aplicada a usuario clave del ERP ISI Mustang

Objetivo: relevar, desde la perspectiva operativa de un usuario clave, las desviaciones y riesgos más frecuentes en la gestión de proyectos de ingeniería, las características y la calidad de los datos históricos registrados en el ERP, y las necesidades y expectativas respecto al módulo de inteligencia predictiva propuesto.

Modalidad: entrevista semiestructurada e individual. El entrevistado otorgó su consentimiento para el registro de la conversación. La información se presenta de forma anonimizada y se utiliza únicamente con fines académicos en el marco del presente proyecto de grado.

Entrevistado (código):	E-01
Cargo / rol:	Jefe de Proyectos
Área o departamento:	Gerencia de Proyectos
Antigüedad en la empresa:	8 años
Fecha y duración:	12 de junio de 2026 — 40 minutos

Bloque I. Contexto del rol y gestión de proyectos

1. ¿Cuál es su rol y cuáles son sus principales responsabilidades en la gestión de proyectos dentro de ISI Mustang?

R: Soy Jefe de Proyectos. Me encargo de la planificación, el seguimiento y el control de los proyectos asignados: armo el cronograma, coordino los recursos y el personal, hago el seguimiento del avance y de los costos, y reporto el estado a la gerencia. Básicamente soy el responsable de que el proyecto se entregue en plazo, en presupuesto y con la calidad comprometida.

2. ¿Qué tipo de proyectos de ingeniería (EPC) gestiona habitualmente y cuál es su duración y envergadura típicas?

R: Trabajamos proyectos EPC para los sectores de gas y petróleo, energía y minería, sobre

todo de fabricación y montaje. La duración varía bastante, normalmente entre seis y dieciocho meses, y son proyectos de presupuesto alto, donde una desviación pequeña en porcentaje ya representa montos importantes.

3. ¿Cuáles son las decisiones más críticas que debe tomar durante la planificación y el seguimiento de un proyecto?

R: Las más críticas tienen que ver con la asignación de recursos y con los ajustes de cronograma cuando algo se atrasa. También las decisiones de compra y requisición de materiales, porque si una compra se demora arrastra a todo el proyecto.

Bloque II. Desviaciones y riesgos (el problema)

1. ¿Qué tipos de desviaciones son las más frecuentes en sus proyectos: sobrecostos, retrasos en plazos, asignación de recursos o certificaciones?

R: Las más frecuentes son los retrasos en los plazos y los sobrecostos, y muchas veces van de la mano. Buena parte se origina en la asignación de recursos y en observaciones que aparecen en las certificaciones, que obligan a rehacer trabajo.

2. ¿Cómo y en qué momento se detectan actualmente esas desviaciones?

R: Hoy las detectamos a través de los reportes del ERP y en las reuniones de avance, que son mensuales o quincenales. El problema es que para cuando el reporte muestra la desviación, esta ya ocurrió; estamos mirando hacia atrás.

3. ¿La detección suele ser oportuna o más bien reactiva? ¿Qué consecuencias trae detectarlas de forma tardía?

R: Es bastante reactiva, esa es la verdad. Cuando se detecta tarde ya hay retrabajos, a veces penalidades por incumplimiento de plazos y sobrecostos que ya no se pueden recuperar. Reaccionamos en lugar de prevenir.

4. Desde su experiencia, ¿qué causas originan con mayor frecuencia esas desviaciones?

R: Suelen ser estimaciones iniciales demasiado optimistas, cambios de alcance durante la ejecución, demoras en las requisiciones de compra y observaciones en certificación que generan reprocesos.

Bloque III. Uso del ERP y datos disponibles (la data)

1. ¿Qué módulos del ERP utiliza con mayor frecuencia y para qué tareas?

R: Uso a diario los módulos de proyectos, certificaciones, el de horas y personal, y el de requisiciones y compras. Sobre todo para cargar y revisar avances, controlar costos y hacer seguimiento al estado de las compras.

2. ¿Qué información registra y qué información consulta habitualmente en el sistema?

R: Registro avances, horas trabajadas, certificaciones y estados de requisición. Consulto principalmente los reportes de avance físico y de costos, y el estado de las certificaciones de cada proyecto.

3. En el módulo de certificaciones, ¿cómo se registran las desviaciones y sus causas? ¿Qué campos se completan?

R: En certificaciones se registra la certificación con sus fechas, el responsable y, cuando hay una observación o desviación, se anota la causa en un campo destinado a eso. El dato existe, pero a veces la descripción de la causa queda muy breve o genérica, depende de quién la cargue.

4. ¿Considera que el historial almacenado en el ERP refleja fielmente lo que realmente ocurre en los proyectos?

R: En lo general sí, la información troncal está. Pero el nivel de fidelidad depende mucho de la disciplina de carga de cada persona; hay detalles que se pierden porque no siempre se registran en el momento.

Bloque IV. Calidad y confiabilidad del registro (calidad de datos)

1. ¿Con qué nivel de detalle y de consistencia se cargan los datos en el sistema?

R: Los datos clave, como fechas, montos y responsables, se cargan de forma bastante consistente. Donde hay más variabilidad es en los comentarios y en el detalle de las causas, que dependen del criterio de cada usuario.

2. ¿Ha identificado inconsistencias, datos faltantes o registros duplicados en el historial?

R: Sí, ocurre. Hay campos que quedan vacíos, fechas que se cargan días después de lo real

y, cuando se corrige un registro, a veces queda algún duplicado. No es masivo, pero está presente.

3. ¿Qué tan estandarizado está el proceso de registro entre las distintas personas o áreas que alimentan el ERP?

R: Está parcialmente estandarizado. Tenemos formatos y procedimientos, pero la manera de describir las causas o de clasificar una observación no es uniforme entre todas las áreas.

Bloque V. Necesidades y expectativas del módulo predictivo

1. ¿Qué predicciones le resultarían más útiles: anticipación de sobrecostos, de retrasos, de cuellos de botella en recursos u otras?

R: Las más útiles serían anticipar retrasos y sobrecostos, y poder ver con tiempo dónde se van a generar cuellos de botella en los recursos. Eso me permitiría redistribuir antes de que el problema golpee.

2. ¿Con qué anticipación necesitaría recibir esas alertas para que le resulten verdaderamente accionables?

R: Idealmente con dos a cuatro semanas de anticipación. Con ese margen todavía puedo reasignar recursos, adelantar una compra o ajustar el cronograma; con menos tiempo ya es solo apagar incendios.

3. ¿Cómo y dónde preferiría visualizar esta información: un tablero (dashboard), dentro del propio ERP, mediante notificaciones?

R: Lo ideal sería un tablero dentro del mismo ERP, con una vista tipo semáforo por proyecto, y que además me lleguen notificaciones cuando un indicador se ponga en riesgo. Que no tenga que entrar a buscarlo.

4. ¿Qué criterios utilizaría para confiar en una predicción generada por el sistema?

R: Que haya acertado en casos pasados que yo conozco, que me explique en qué se basa la alerta y no sea una caja negra, y que sea consistente en el tiempo. La confianza se gana con aciertos.

5. ¿Qué impacto esperaría que tuviera esta herramienta en su trabajo diario y en la gestión de los proyectos?

R: Esperaría pasar de una gestión reactiva a una preventiva. Si logramos anticiparnos, se reducen los sobrecostos y mejora el cumplimiento de plazos, y mi equipo trabaja con menos urgencias de último momento.

Bloque VI. Cierre

1. ¿Desea añadir algún comentario, observación o sugerencia adicional respecto al tema tratado?

R: Solo que sea una herramienta fácil de usar y que no agregue carga de trabajo de carga de datos. Y como sugerencia, empezaría por el módulo de certificaciones, que es donde tenemos el historial más rico de desviaciones.